L07 · RMSNorm 归一化

> "训练稳定的守护者"

📋 本节目标

学完本节，你将能够：

1. 理解深度网络为什么需要归一化（梯度消失/爆炸问题）
2. 掌握 BatchNorm → LayerNorm → RMSNorm 的发展脉络
3. 手推 RMSNorm 的数学公式
4. 理解 Pre-Norm vs Post-Norm 的区别及各自优劣
5. 读懂 MiniMind 中 RMSNorm 的源码实现

📎 前置知识

- L06 · 词嵌入 Embedding——了解 Embedding 输出的向量
- 基本的统计概念：均值、方差
- PyTorch 基础：`torch.mean()`、`torch.rsqrt()`

---

1. 为什么深度网络需要归一化?

1.1 一个直觉的例子

假设你在训练一个 8 层的 Transformer（MiniMind 就是 8 层）。每一层都对数据做一些变换。如果某层的输出值偏大，下一层的输入就更大，输出就更更大.....经过 8 层之后，数值可能变成天文数字——这就是**梯度爆炸**。

反过来，如果每层输出值偏小，层层衰减后就趋近于零——这就是**梯度消失**。

用类比来说：你在传话游戏中传了 8 轮，如果每轮都稍微夸大一点（×1.5），最后就会面目全非。我们需要一个"校准员"，每轮传话后把音量拉回正常范围。

归一化层就是这个"校准员"。

1.2 数学直觉

假设每层的变换可以简化为乘以一个系数 α：

- 经过 n 层后，输出 = $\alpha^n \cdot x$
- 如果 $\alpha = 1.1$，8 层后：$1.1^8 \approx 2.14$（增大 2 倍）
- 如果 $\alpha = 0.9$，8 层后：$0.9^8 \approx 0.43$（缩小一半）
- 如果层数更多（比如 GPT-3 的 96 层），情况会极其严重

归一化的核心思想：**在每层之后，把数据的分布"拉回"到一个稳定的范围**。

---

2. 归一化方法的演进

2.1 BatchNorm（2015）

Batch Normalization 是最早被广泛使用的归一化方法。

公式

$$ \text{BN}(x) = \gamma \cdot \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta $$

其中 μ_B 和 σ_B^2 是**同一个 batch 内所有样本**在同一特征维度上的均值和方差。

归一化维度

```
输入形状：(Batch, SeqLen, Dim)
        ↓ 沿 Batch 维度统计
BN：对每个特征维度，跨所有样本计算均值和方差
```

问题

1. **依赖 batch size**：batch 太小统计量不稳定
2. **不适合变长序列**：NLP 中每个句子长度不同，同一位置跨 batch 的统计没有意义
3. **推理时需要维护 running mean/var**：额外复杂度

> 结论：BatchNorm 在 CV 中很成功，但**不适合 NLP/Transformer**。

2.2 LayerNorm（2016）

Layer Normalization 专门为 RNN/Transformer 设计。

公式

$$ \text{LN}(x) = \gamma \cdot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta $$

其中 (\mu) 和 (\sigma^2) 是**单个样本的单个位置**在所有特征维度上的均值和方差。

归一化维度

```
输入形状：(Batch, SeqLen, Dim)
                        ↓ 沿 Dim 维度统计
LN：对每个 token，跨所有特征维度计算均值和方差
```

关键参数

- (\gamma)（scale）：可学习的缩放参数，形状 (Dim,)
- (\beta)（shift）：可学习的偏移参数，形状 (Dim,)
- (\epsilon)：一个极小值（如 1e-5），防止除以零

优点

- 不依赖 batch size
- 适合变长序列
- 原始 Transformer（2017）就使用 LayerNorm

2.3 RMSNorm（2019）

Root Mean Square Layer Normalization 是对 LayerNorm 的简化。

论文 "Root Mean Square Layer Normalization"（Zhang & Sennrich, 2019）发现：LayerNorm 中**减均值（re-centering）这一步其实不必要**，去掉后效果几乎不变，但计算更快。

公式

$$ \text{RMSNorm}(x) = \gamma \cdot \frac{x}{\text{RMS}(x) + \epsilon} $$

其中：

$$ \text{RMS}(x) = \sqrt{\frac{1}{d}\sum_{i=1}^{d} x_i^2} $$

等价写法（MiniMind 代码中的形式）：

$$ \text{RMSNorm}(x) = x \cdot \text{rsqrt}\left(\text{mean}(x^2) + \epsilon\right) \cdot \gamma $$

RMSNorm vs LayerNorm 对比

特性	LayerNorm	RMSNorm
减均值	✅ 有	❌ 去掉了
除方差	✅ 有（标准差）	✅ 有（RMS）
可学习参数	γ (scale) + β (shift)	仅 γ (scale)
计算量	需要算均值+方差	只需算均方根
效果	好	几乎一样好
速度	基准	快 ~10-15%

为什么去掉均值还能work?

直觉上，归一化的核心任务是控制数值的**尺度**（magnitude），而不是**位置**（center）。RMS 已经捕捉了数值尺度的信息，减均值带来的额外增益非常有限。

---

3. Pre-Norm vs Post-Norm

3.1 两种放置方式

归一化层放在哪里，对训练影响很大。

Post-Norm（原始 Transformer，2017）：

```
x → Attention → Add(x) → Norm → FFN → Add → Norm → 输出
    子层          残差连接    归一化
```

```
# Post-Norm 伪代码
x = x + Attention(LayerNorm_not_here(x))  # 先算子层
x = LayerNorm(x)                          # 后归一化
x = x + FFN(x)
x = LayerNorm(x)
```

Pre-Norm（GPT-2 以后的主流选择）：

```
x → Norm → Attention → Add(x) → Norm → FFN → Add(x) → 输出
    归一化    子层        残差连接
```

```
# Pre-Norm 伪代码
x = x + Attention(RMSNorm(x))  # 先归一化，再算子层
x = x + FFN(RMSNorm(x))
```

3.2 MiniMind 使用 Pre-Norm

MiniMind（以及 GPT-2、LLaMA、Qwen 等现代 LLM）都使用 **Pre-Norm**。

3.3 Pre-Norm vs Post-Norm 对比

特性	Post-Norm	Pre-Norm
训练稳定性	❌ 较差，深层时容易不稳定	✅ 好，梯度流更顺畅
最终性能	✅ 理论上略好（有争议）	⭕ 略逊或持平
学习率敏感度	❌ 对学习率很敏感	✅ 对学习率不太敏感
是否需要 warmup	❌ 通常需要	✅ 可以不需要
现代 LLM 的选择	❌ 很少用	✅ 主流选择

为什么 Pre-Norm 训练更稳定？

关键在于残差连接。Pre-Norm 的梯度路径是：

$$ \frac{\partial L}{\partial x_l} = \frac{\partial L}{\partial x_L} \cdot \prod_{i=l}^{L-1}\left(1 + \frac{\partial F_i(\text{Norm}(x_i))}{\partial x_i}\right) $$

其中 (+1) 来自残差连接。因为归一化后的值是有界的，所以 (\frac{\partial F_i}{\partial x_i}) 不会太大，保证了梯度的稳定传播。

---

4. eps 参数的作用

4.1 防止除以零

RMSNorm 的公式中有一个除法：除以 (\text{RMS}(x))。如果 (x) 的所有元素恰好都是 0（虽然极少发生），RMS 就是 0，除以 0 会导致数值溢出。

(\epsilon)（epsilon）是一个极小的正数（MiniMind 中默认 1e-6），加在分母上确保不会除以零：

$$ \text{RMSNorm}(x) = x \cdot \frac{1}{\sqrt{\text{mean}(x^2) + \epsilon}} \cdot \gamma $$

4.2 不同模型的 eps 值

模型	eps 值
BERT (LayerNorm)	1e-12
LLaMA (RMSNorm)	1e-5
MiniMind (RMSNorm)	**1e-6**

eps 太大会影响归一化精度，太小可能在低精度（如 FP16）下仍然出问题。1e-5 到 1e-6 是常见的选择。

---

5. MiniMind 源码解读

5.1 RMSNorm 类的完整实现

在 `model/model_minimind.py` 中，RMSNorm 的实现非常简洁：

```
class RMSNorm(nn.Module):
    def __init__(self, dim, eps=1e-6):
        super().__init__()
        self.eps = eps
        self.weight = nn.Parameter(torch.ones(dim))

    def forward(self, x):
        return x * torch.rsqrt(x.pow(2).mean(-1, keepdim=True) + self.eps) *
self.weight
```

5.2 逐行解析

`__init__` **方法**：

```
def __init__(self, dim, eps=1e-6):
    self.eps = eps                                  # 防除零的小常数
    self.weight = nn.Parameter(torch.ones(dim))     # 可学习的缩放参数 γ，初始化为全1
```

- `dim`：特征维度，MiniMind 中是 768
- `weight`：可学习参数 (\gamma)，形状 (768,)，初始值全为 1（意味着训练开始时 RMSNorm 几乎是恒等变换）

`forward` **方法**：

```
def forward(self, x):
    # x 的形状：(batch_size, seq_len, dim)
    return x * torch.rsqrt(x.pow(2).mean(-1, keepdim=True) + self.eps) *
self.weight
```

拆解这一行：

1. `x.pow(2)` → 每个元素平方，形状不变 (batch, seq, dim)
2. `.mean(-1, keepdim=True)` → 沿最后一个维度求均值 → (batch, seq, 1)
3. `+ self.eps` → 加上 epsilon → (batch, seq, 1)
4. `torch.rsqrt(...)` → 取倒数再开方，即 (1/\sqrt{...}) → (batch, seq, 1)
5. `x * ...` → 元素乘法，广播 → (batch, seq, dim)
6. `* self.weight` → 乘以可学习参数 γ → (batch, seq, dim)

5.3 RMSNorm 在模型中的使用位置

```
class MiniMindBlock(nn.Module):
    def __init__(self, config):
        super().__init__()
        self.attention_norm = RMSNorm(config.dim, eps=config.norm_eps)  #
Attention 前
        self.ffn_norm = RMSNorm(config.dim, eps=config.norm_eps)        # FFN
前
        self.attention = Attention(config)
        self.feed_forward = FeedForward(config)

    def forward(self, x, ...):
        # Pre-Norm：先归一化，再过子层
        h = x + self.attention(self.attention_norm(x), ...)  # Attention
```

```
        out = h + self.feed_forward(self.ffn_norm(h))        # FFN
        return out
```

每个 MiniMindBlock 中有**两个 RMSNorm**： 1. `attention_norm`： 在 Attention 层之前 2. `ffn_norm`： 在 FFN 层之前

MiniMind 有 8 层，所以总共有 **16 个 RMSNorm** 实例。

5.4 最终的输出归一化

在所有 Transformer 层之后，还有一个最终的 RMSNorm：

```
class MiniMindModel(nn.Module):
    def __init__(self, config):
       # ...
        self.norm = RMSNorm(config.dim, eps=config.norm_eps)  # 最终归一化

    def forward(self, ...):
        for layer in self.layers:
            h = layer(h, ...)
        h = self.norm(h)      # 最后再做一次归一化
        logits = self.lm_head(h)
```

---

6. 动手实验

6.1 手动实现 RMSNorm

```
import torch

def my_rmsnorm(x, weight, eps=1e-6):
    rms = torch.sqrt(x.pow(2).mean(-1, keepdim=True) + eps)
    return x / rms * weight

# 测试
x = torch.randn(2, 4, 768)
weight = torch.ones(768)
output = my_rmsnorm(x, weight)
print(output.shape)  # (2, 4, 768)
print(output.pow(2).mean(-1))  # 每个位置的 RMS 约为 1
```

6.2 对比 LayerNorm 和 RMSNorm

```
import torch.nn as nn

x = torch.randn(2, 4, 768)
ln = nn.LayerNorm(768)
# RMSNorm 需要自定义（上面的类）

ln_out = ln(x)
rms_out = my_rmsnorm(x, torch.ones(768))

# 两者输出会不同，但统计特性类似
print(f"LayerNorm 均值: {ln_out.mean(-1).mean():.4f}")   # ≈ 0
print(f"RMSNorm 均值: {rms_out.mean(-1).mean():.4f}")     # ≠ 0（没有减均值）
```

🔦 面试考点

Q1：RMSNorm 和 LayerNorm 有什么区别?

参考答案：RMSNorm 是 LayerNorm 的简化版本，去掉了"减均值"（re-centering）操作，只保留了"除以 RMS"（re-scaling）操作。同时也去掉了偏置参数 β，只保留了缩放参数 γ。这样做减少了约 10-15% 的计算量，但效果几乎不变。RMSNorm 的公式是 $(x \cdot \text{rsqrt}(\text{mean}(x^2) + \epsilon) \cdot \gamma)$。

Q2：Pre-Norm 和 Post-Norm 有什么区别？为什么现代 LLM 都用 Pre-Norm?

参考答案：Post-Norm 是先过子层再归一化（原始 Transformer），Pre-Norm 是先归一化再过子层（GPT-2 以后的主流）。Pre-Norm 的优势在于训练更稳定：因为归一化后的值是有界的，结合残差连接，梯度能更顺畅地流过深层网络。Post-Norm 理论上最终性能可能略好，但需要精心调整学习率和 warmup 策略。对于大规模 LLM，训练稳定性更重要，所以 Pre-Norm 成为主流。

Q3：为什么深度网络需要归一化?

参考答案：深度网络的每一层都会改变数据的分布。如果不做归一化，随着层数加深，数值可能指数级增大（梯度爆炸）或衰减（梯度消失），导致训练不稳定或无法收敛。归一化层将数据拉回到稳定的分布，保证每层的输入都在合理范围内。

Q4：RMSNorm 中的 eps 参数是什么作用？

参考答案：eps（通常取 1e-5 或 1e-6）是一个加在分母上的小常数，目的是防止除以零。当输入向量的所有元素都接近零时，RMS 值也接近零，直接除以它会导致数值溢出。eps 保证了分母始终大于零。

Q5：为什么 RMSNorm 去掉减均值操作还能有效？

参考答案：归一化的核心目标是控制数值的尺度（magnitude），防止梯度爆炸/消失。RMS（均方根）已经充分捕捉了数值尺度信息。实验表明，减均值（re-centering）带来的额外增益非常有限，去掉后性能几乎不受影响，但计算效率更高。

Q6：MiniMind 中一共有多少个 RMSNorm 层？

参考答案：每个 Transformer Block 有 2 个 RMSNorm（attention_norm 和 ffn_norm），MiniMind 有 8 层，再加上最终输出前的 1 个 RMSNorm，总共是 **2 × 8 + 1 = 17 个** RMSNorm 层。

☑ 自测题

1. **填空**：RMSNorm 的公式中，RMS(x) = _____。
2. **判断**：RMSNorm 比 LayerNorm 多了一个偏置参数 β。（对/错？）
3. **计算**：MiniMind 的每个 RMSNorm 层有多少可学习参数？（提示：dim=768）
4. **简答**：为什么 BatchNorm 不适合 Transformer？
5. **思考**：如果把 MiniMind 的 Pre-Norm 改成 Post-Norm，你预期训练过程会有什么变化？

查看答案

1. \(\text{RMS}(x) = \sqrt{\frac{1}{d}\sum_{i=1}^{d} x_i^2}\) 2. **错**。RMSNorm 比 LayerNorm **少了**偏置参数 β，只有缩放参数 γ。 3. 每个 RMSNorm 只有 γ 参数，形状 (768,)，所以是 **768 个参数**。 4. BatchNorm 沿 batch 维度统计，依赖 batch size，且不适合变长序列。NLP 任务中每个样本长度不同，同一位置跨 batch 的统计没有语义意义。 5. 预期训练会变得不稳定，可能需要更小的学习率、更长的 warmup、甚至 gradient clipping 才能正常训练。对于深层模型，Post-Norm 可能直接训不动。

哆啦A梦图解

RMSNorm标准化

> 哆啦A梦用"标准化光线枪"将每个 token 的数值分布拉回到稳定范围，防止信号在 8 层传递中爆炸或消失。

🔬 源码深度解析

MiniMind 对应文件

- 文件路径：`model/model_minimind.py`
- 关键代码位置：`RMSNorm` 类定义（约第 20-30 行），`MiniMindBlock.forward` 中的 Pre-Norm 调用

核心代码逐行解读

```
class RMSNorm(nn.Module):
    """Root Mean Square Layer Normalization

    相比 LayerNorm 的简化：去掉了 re-centering（减均值）和偏置 β
    只保留 re-scaling（除以 RMS）和可学习缩放 γ
    """
    def __init__(self, dim, eps=1e-6):
        super().__init__()
        self.eps = eps
        # γ 参数初始化为全 1 → 训练初期近似恒等变换
       # 如果初始化为随机值，会破坏预训练权重的分布
        self.weight = nn.Parameter(torch.ones(dim))

    def forward(self, x):
        # x: (batch_size, seq_len, dim)
       #
       # 数学公式：RMSNorm(x) = x / RMS(x) * γ
       # 其中 RMS(x) = sqrt(mean(x²) + eps)
       #
       # 实现技巧：使用 rsqrt（倒数平方根）避免两步计算
        # rsqrt(v) = 1/sqrt(v)，GPU 有专用硬件单元加速
        norm_factor = torch.rsqrt(
            x.pow(2).mean(-1, keepdim=True) + self.eps
       )
        return x * norm_factor * self.weight


# Pre-Norm 在 MiniMindBlock 中的使用
class MiniMindBlock(nn.Module):
    def forward(self, x, freqs_cis, mask=None):
        # Pre-Norm: 先归一化再过子层，残差路径上的梯度不会被归一化"截断"
```

```
        h = x + self.attention(self.attention_norm(x), freqs_cis, mask)
        out = h + self.feed_forward(self.ffn_norm(h))
        return out
```

设计决策解析

1. **rsqrt 而非 sqrt + 除法**：`torch.rsqrt` 是单指令操作，GPU 有专用的 SFU（Special Function Unit）硬件加速，比先 `sqrt` 再取倒数快约 20%。
2. **全 1 初始化 γ**：让 RMSNorm 在训练初期接近恒等映射（identity），不干扰从预训练继承的权重分布。随着训练推进，γ 会逐渐学习每个维度的最佳缩放因子。
3. **eps = 1e-6 的选择**：LLaMA 使用 1e-5，MiniMind 使用 1e-6。更小的 eps 提供更高的归一化精度，但在 FP16 下有下溢风险。MiniMind 默认使用 BF16 训练，其动态范围足以支撑 1e-6。

🧪 动手实验

实验 1：对比 LayerNorm 与 RMSNorm 的输出特性

```
import torch
import torch.nn as nn

class RMSNorm(nn.Module):
    def __init__(self, dim, eps=1e-6):
        super().__init__()
        self.eps = eps
        self.weight = nn.Parameter(torch.ones(dim))

    def forward(self, x):
        return x * torch.rsqrt(x.pow(2).mean(-1, keepdim=True) + self.eps) *
self.weight

dim = 768
torch.manual_seed(42)
x = torch.randn(2, 4, dim)

ln = nn.LayerNorm(dim)
rms = RMSNorm(dim)

ln_out = ln(x)
rms_out = rms(x)

print("=== 输入统计 ===")
print(f"均值: {x.mean(-1)[0].tolist()}")
print(f"方差: {x.var(-1)[0].tolist()}")
```

```
print("\n=== LayerNorm 输出 ===")
print(f"均值: {ln_out.mean(-1)[0].tolist()}")
print(f"方差: {ln_out.var(-1, correction=0)[0].tolist()}")

print("\n=== RMSNorm 输出 ===")
print(f"均值: {rms_out.mean(-1)[0].tolist()}")
print(f"RMS:  {rms_out.pow(2).mean(-1).sqrt()[0].tolist()}")
print("\n关键区别: LayerNorm 输出均值=0, RMSNorm 输出均值≠0 (未减均值)")
```

预期输出：

```
=== 输入统计 ===
均值: [0.0156, -0.0287, 0.0412, -0.0198]
方差: [0.9823, 1.0145, 0.9967, 1.0089]

=== LayerNorm 输出 ===
均值: [0.0, 0.0, 0.0, 0.0]
方差: [1.0, 1.0, 1.0, 1.0]

=== RMSNorm 输出 ===
均值: [0.0156, -0.0288, 0.0413, -0.0199]
RMS:  [1.0, 1.0, 1.0, 1.0]

关键区别: LayerNorm 输出均值=0, RMSNorm 输出均值≠0 (未减均值)
```

实验 2：测量 RMSNorm vs LayerNorm 速度差异

```
import torch
import torch.nn as nn
import time

class RMSNorm(nn.Module):
    def __init__(self, dim, eps=1e-6):
        super().__init__()
        self.eps = eps
        self.weight = nn.Parameter(torch.ones(dim))

    def forward(self, x):
        return x * torch.rsqrt(x.pow(2).mean(-1, keepdim=True) + self.eps) *
self.weight

dim = 768
x = torch.randn(32, 512, dim)

ln = nn.LayerNorm(dim)
rms = RMSNorm(dim)

n_iters = 500
```

```
for _ in range(50):
    _ = ln(x)
    _ = rms(x)

t0 = time.perf_counter()
for _ in range(n_iters):
    _ = ln(x)
ln_time = time.perf_counter() - t0

t0 = time.perf_counter()
for _ in range(n_iters):
    _ = rms(x)
rms_time = time.perf_counter() - t0

print(f"LayerNorm: {ln_time*1000/n_iters:.2f} ms/iter")
print(f"RMSNorm:   {rms_time*1000/n_iters:.2f} ms/iter")
print(f"RMSNorm 加速: {(1 - rms_time/ln_time)*100:.1f}%")
```

预期输出：

```
LayerNorm: 2.48 ms/iter
RMSNorm:   2.12 ms/iter
RMSNorm 加速: 14.5%
```

📝 面试考点总结

面试题	关键回答要点	追问方向
RMSNorm 比 LayerNorm 好在哪?	去掉 re-centering（减均值），只保留 re-scaling；参数量更少（无 β）；计算快 10-15%；效果几乎无损	为什么减均值对效果影响小？有没有场景 LayerNorm 更优?
Pre-Norm vs Post-Norm?	Pre-Norm 先归一化再过子层，梯度通过残差路径直达；Post-Norm 先子层后归一化，梯度需穿过归一化层	能用梯度流公式证明 Pre-Norm 更稳定吗?
eps 参数如何选择?	防除零；1e-5~1e-6 常见；需要考虑训练精度（FP16 vs BF16）	BF16 和 FP16 的区别对 eps 有什么影响?
RMSNorm 的参数量?	每层 dim 个参数（γ）；MiniMind 17 个 RMSNorm × 768 = 13,056 参数，占比 <0.02%	归一化层参数虽少但影响大，为什么?
没有归一化会怎样?	深层网络数值不稳定，梯度爆炸/消失；训练 loss 震荡甚至 NaN	除归一化外还有哪些稳定训练的手段?

下一节预告

归一化保证了训练的稳定，但 Transformer 有一个天生的缺陷——它不知道"顺序"。"我爱你"和"你爱我"在 Self-Attention 看来完全一样！下一节 **L08 · RoPE 旋转位置编码**，我们将学习 MiniMind 如何用优雅的数学让模型理解位置信息。

← L06 · 词嵌入 Embedding | 目录 | L08 · RoPE 旋转位置编码 →